


Поиск аномалий и точек смены поведения

Введение


Откуда взялась такая задача?

Аномальное поведение



Аномальные точки

Произошло что-то непонятное единоразово




Точки смены поведения

Произошло что-то непонятное и ряд начал вести себя по-другому

Задача прогнозирования

Идея: удаление аномалий из данных улучшает качество решения целевой задачи(прогнозирования)




Мониторинг бизнес-процессов

Идея: хотим искать аномалии сами по себе – отражают сбои/изменения в бизнес-процессах

Примеры:

1. Резко выросло количество обращений в колл-центр(срочно ищем проблему)
2. У метрики лояльности поменялся тренд(почему?)



Мониторинг бизнес-процессов



От данных к инсайту:

стратегия эффективного
оффлайн мониторинга



[Максим Жерело | От данных к инсайту:
стратегия эффективного оффлайн мониторинга](#)

Скоринг аномалий для
превентивного выявления
сбоев информационных
систем

Алгазинов Александр



Data Fest 2024 • RANDOM DS/ML



[Александр Алгазинов | Скоринг аномалий для
превентивного выявления сбоев
информационных систем](#)

Мониторинг промышленных процессов

Анализ поведения показателей с различных датчиков в рамках промышленного процесса

Примеры:

1. Резкое повышение температуры
2. Скачки напряжения






[Юрий Кацер - SKAB и другие open-source бенчмарки для задач обнаружения аномалий в промышленности](#)

Мониторинг промышленных процессов

SKAB -- Skoltech Anomaly Benchmark

- 34 штуки
- Аномалии в метриках промышленной установки
- Температура, вибрация, напряжение, ...



Испытательный стенд

Стенд состоит из следующих систем:

- 01 Система циркуляции воды
- 02 Система мониторинга состояния системы циркуляции воды
- 03 Система контроля и управления системой циркуляции воды
- 04 Система демонстрации технологии Time-Sensitive Networking (TSN)
- 05 Система сбора, обработки и визуализации данных

Фокус



Передняя панель и состав систем циркуляции воды, мониторинга, контроля и управления:
1 - водяной бак; 2 - водяной насос; 3 - электродвигатель; 4 - клапаны; 5 - механический рычаг для обеспечения несоосности валов; 6 - кнопка аварийной остановки.

Датчики:
7 - датчик расхода (NI 9401 8-channel); 8 - датчик давления (NI 9203 8-channel); 9, 10 - вибродатчики (NI 9232 3-channel); 11, 12 - термодатчики (NI 9213 Spring Terminal 16-channel thermocouple).

Мониторинг IT систем

Детектируем аномалии в показателях технических метрик(часто real-time)



- Потребление CPU/RAM
- Количество запросов к системе (RPS)
- Фон ошибок/логов



Мониторинг IT систем

NAB -- Numenta Anomaly Benchmark

- 58 штук -- синтетика + реальные
- AWS server metrics, Twitter volume, advertisement clicking metrics, traffic data
- Streaming anomaly detection



И другие...

Детекция фрода


Примеры:

1. Большая сумма транзакции за границей
2. Необычные паттерн транзакций – частые мелкие транзакции

Мониторинг в здравоохранении


Примеры:

1. Нехарактерный ритм биения сердца на ЭКГ
2. Смена уровня показателей пациента (пульс/дыхание/давление...)




Методы поиска точечных аномалий

Формализация



Хотим создать некоторый оракул (f), который
выставляет высокий скор для аномалий и
низкий для нормальных наблюдений

Таксономия(по домену)



Таксономия(по стратегии обнаружения)

online



Количество ответов с
ошибкой

Хотим моментально реагировать на сбои

Количество обращений
в поддержку

Хотим своевременно распределять нагрузку

Метрики
удовлетворенности
пользователей

Хотим понимать все ли в порядке с продуктом

offline

Таксономия(по стратегии обнаружения)


Offline

- Меньше требований к скорости работы
- Доступны данные за весь анализируемый промежуток
- Частотность
 - Дневная
 - Недельная
 - Месячная

Online

- Жесткие ограничения на время работы – должны обнаружить аномалию как можно быстрее
- Доступны только исторические данные
- Частотность
 - Минутные
 - Часовые

Таксономия(по наличию разметки)



Чаще используются эти подходы из-за проблем с разметкой

Оценка качества

1. Метрики классификации:

- Precision

$$Precision = \frac{TP}{TP + FP}$$

- Recall

$$Recall = \frac{TP}{TP + FN}$$

- F-beta

$$F_{\beta} = \frac{(1 + \beta^2) Precision Recall}{\beta^2 Precision + Recall}$$

А разметку где брать?

2. Метрики downstream задач

- Прогнозирование → MAE

Разметка не нужна

Supervised методы и разметка данных

Classification Model

timestamp	target	features	class
01-01-24	2	4	0
02-01-24	10	3	0
03-01-24	100	2	1
04-01-24	3	4	0



CatBoost

Плюсы:

- Подстраивается под конкретную задачу

Минусы:

- Нужна разметка
- Мало позитивов

В чем сложность?

- Готовой разметки чаще всего нет
 - Не можем учить supervised
 - Не можем оценить качество
- Нет четкой формализации “что такое аномалия”
 - Ищем что-то неопределенное
- Долго и дорого собирать разметку

Основные подходы


Реально собираем разметку

1. Экспертная разметка – просим эксперта разметить его данные
2. Разметка по фидбэку – просим эксперта провалидировать данные с предразметкой

Готовая разметка

1. Открытые датасеты – сложно найти данные, похожие на ваш домен
2. Синтетические данные – нужно потратить время на настройку процесса генерации


Основные подходы



Синтетические данные

Идея: Сгенерируем датасет на основе реальных данных, добавим аномалии, характерные для целевых данных

- (+) Известна точная разметка
- (-) Синтетика не всегда полностью описывает реальные данные



RecSys & TS

**Генерация
синтетических
временных рядов
для решения задачи
поиска аномалий**


Владислав Власов
исследователь-разработчик,
Anomaly Analyzer, Т-Банк

The slide features a dark blue background with a light blue curved shape on the right side containing a portrait of a man with a beard. There are two horizontal bars with blue circles, one at the top right and one at the bottom right.

[Генерация синтетических временных рядов для решения задачи поиска аномалий](#)


Синтетические данные

Можно генерировать синтетику по слоям, аномалии это отдельный слой (будем так делать на семинаре)




Semi-supervised и Unsupervised

AutoEncoders




- Обучим автоэнкодер минимизировать reconstruction loss
- Считаем аномалией все выше порога реконструкции

AutoEncoders



Isolation Forest




Повторяем рекурсивно + много деревьев:


1. Выбираем случайный признак
2. Выбираем случайных порог из значений признака
3. Разделяем сэмплы по порогу

Идея: аномальные точки будут отделяться в отдельные вершины быстрее нормальных

Isolation Forest




Сплиты в дереве для нормальной и аномальной точек




Средняя длина пути для нормальной и аномальной точек с ростом числа деревьев

Isolation Forest




Средняя длина путей в 2d




Решающее правильно в 1d
(сплитимся только по target)

Isolation Forest





OK





Нужна более сложная
решающая поверхность


Isolation Forest



Isolation Forest



Forecasting Model



1. Обучаем модель
2. Строим прогнозы
3. (online)Ждем фактические данные


Плюсы:

- Не нужна разметка
- Учитывает особенности временных рядов(тренд/сезонность/...)

Минусы:

- Работает при условии что модель хорошая

Forecasting Model



Вариации:

1. Доверительные интервалы
2. Прогноз VS Факт – нужно подбирать порог отклонения
3. Двухгоризонтная модель – раннее оповещение о возможных разладках в будущем

Rule Based(Global Statistics)




- **Threshold** – подбираем пороги руками (бизнес-логика)
- **Quantile** – используем квантили в качестве порогов (статистика)
- **IQR** – используем интерквартильный размах как коридор


Будем считать аномалией все, что попадает в интервал

$$Anomaly(t) = I[y_t \in [LowerBound, UpperBound]]$$

Rule Based(STL + IQR)




IQR(y)



IQR(y - seasonal -- trend)

Rule Based(Sliding window statistics)




- Сгенерируем набор окон
- Будем считать статистики внутри окон
- Каждая точка может быть в нескольких окошках → ансамблируем результаты

Можем оценивать пороги динамически


$$Anomaly(t) = I[y_t \in [LowerBound_t, UpperBound_t]]$$

Rule Based(Sliding window statistics)




Аномалии из локального нормального распределения

$$Anomaly(t) = I[y_t \in [\mu_t - \alpha * \sigma_t, \mu_t + \alpha * \sigma_t]]$$




Rule Based(Density)



- Для каждой точки строим окрестность
- Считаем количество соседей в этой окрестности
- Мало соседей → аномалия
- Для каждой точки несколько окон


Ансамблирование(AND)

$$Anomaly(t) = AND(Anomaly_1(t), \dots, Anomaly_n(t))$$



Ансамблирование(OR)

$$Anomaly(t) = OR(Anomaly_1(t), \dots, Anomaly_n(t))$$



Ансамблирование(Model)

$$Anomaly(t) = Model(Anomaly_1(t), \dots, Anomaly_n(t))$$

1. Обучаем базовые детекторы на train
2. Генерируем разметку на test

	timestamp	model_1	model_2	model_3	model_4	target
0	2000-01-01	0	0	1	0	0
1	2000-01-02	0	0	0	1	1
2	2000-01-03	1	1	0	1	1
3	2000-01-04	1	0	1	1	1
4	2000-01-05	0	0	0	0	0
5	2000-01-06	1	1	1	1	1



Ансамблирование


- AND – максимизируем precision(только уверенные аномалии)
- OR – максимизируем recall(все подозрительные точки)
- Model – ”оптимально взвешиваем” мнения алгоритмов
-

Методы поиска точек смены поведения

Формализация

- Необходимо найти набор точек $t_1 \dots t_K$, которые максимизируют гомогенность сегментов
- Функция стоимости (**cost function**) – некоторая оценка гомогенности сегмента


$$(\hat{t}_1, \dots, \hat{t}_K) = \underset{(t_1, \dots, t_K)}{\operatorname{argmin}} \sum_{k=0}^K c(x[t_k : t_{k+1}])$$



Cost Function


L2 – смена уровня

$$c(y_I) = \sum_{t \in I} \|y_t - \bar{y}\|_2^2$$



Linear – смена тренда

$$c(y_I) = \min_{\delta \in \mathbb{R}^p} \sum_{t \in I} \|y_t - \delta' x_t\|_2^2.$$



$K = 7$

Search Method

Точное решение

- Основано на методе динамического программирования
- Находит истинное решение оптимизационной задачи
- Долго работает

Приближенные решения

- Основаны на оценке “аномальности” каждой точки в отдельности
- Находят субоптимальные решения
- Работают быстро
(далее про них)


Логика приближенных решений

Основные компоненты:

1. Стратегия перебора точек
2. Discrepancy function – функция оценки стоимости разделения/слияния отрезков в смысле гомогенности
3. Точки с наибольшим/наименьшим значением discrepancy function и будут искомыми



$$d(y_{u..v}, y_{v..w}) = c(y_{u..w}) - c(y_{u..v}) - c(y_{v..w})$$

Rolling window




- Двигаемся окошком размера $2w$ вдоль ряда
- Делаем оценку для середины окошка

Rolling window




Bottom UP Segmentation



1. Равномерно раскидываем потенциальные точки N
2. Для всех соседних отрезков считаем стоимость слияния
3. Сливаем самую дешевую пару
4. Останавливаемся по критерию

Binary Segmentation




Повторяем рекурсивно:


1. Делим порезок пополам всеми возможными способами
2. Считаем стоимость разбиения для каждого способа
3. Выбираем самый дорогой

Prophet

```
1 ProphetModel(  
2     growth: str = "linear",  
3     changepoints: Optional[List[datetime]] = None,  
4     n_changepoints: int = 25,  
5     changepoint_range: float = 0.8,  
6     changepoint_prior_scale: float = 0.05,  
7 )
```



logistic




flat


linear

growth

change_point_range



1. Равномерно разбрасываем **n_changepoints** на **change_point_range** процентов истории



2. Количество выбранных точек зависит от **changepoint_prior_scale**

Prophet



$$g(t) = (k + \mathbf{a}(t)^\top \boldsymbol{\delta})t + (m + \mathbf{a}(t)^\top \boldsymbol{\gamma})$$

$$\delta_j \sim \text{Laplace}(0, \tau).$$

MAP оценка

$$\hat{\theta}_{\text{MAP}}(x) = \arg \max_{\theta} f(\theta | x)$$

(аналогично Lasso регрессии)



Заключение

Особенности задачи

- Сложно оценивать качество
- Нет общепринятых бенчмарков
- Тонкая настройка под заказчика
- SLA на время отклика
- Необходима адаптация методов под особенности Time Series

Про что поговорили

- Где возникает задача обнаружения аномалий
- Как собирать разметку
- Методы обнаружения точечных аномалий
- Методы обнаружения точек смены поведения

Библиотеки

- [ruptures](#) – больше про сегментацию
- [ADTK](#) – rule-based подходы
- [PyOD](#) – методы для табличек
- Фрэймворки....

Спасибо за внимание!