Catch 22

Catch22

Идея: найдем минимальный по количеству и максимально разнообразный набор фичей, который хорошо работает на любой задаче классификации

- Сделали фильтрацию 7658 -> 22 фичи
- Подбирали под 93 классификационных датасета

Dataset	Train Size	Test Size	Length	No. of Classes	Type
AbnormalHeartbeat	303	303	3053	5	AUDIO
ACSF1	100	100	1460	10	DEVICE
Adiac	390	391	176	37	IMAGE
AllGestureWiimoteX	300	700	0	10	HAR
AllGestureWiimoteY	300	700	0	10	HAR
AllGestureWiimoteZ	300	700	0	10	HAR
ArrowHead	36	175	251	3	IMAGE
ArticularyWordRecognition	275	300	144	25	MOTION
AsphaltObstacles	390	391	0	4	MOTION
AsphaltObstaclesCoordinates	390	391	0	4	MOTION
AsphaltPavementType	1055	1056	0	3	MOTION
AsphaltPavementTypeCoordinates	1055	1056	0	3	MOTION
AsphaltRegularity	751	751	0	2	MOTION
AsphaltRegularityCoordinates	751	751	0	2	MOTION
AtrialFibrillation	15	15	640	3	ECG

https://www.timeseriesclassification.com/

catch22: CAnonical Time-series CHaracteristics

Catch22(Фичи)

- **basic statistics** of time-series values (e.g., location, spread, Gaussianity, outlier properties)
- **linear correlations** (e.g., autocorrelation, power spectral features)
- **stationarity** (e.g., StatAv, sliding window measures, prediction errors)
- **entropy** (e.g., auto-mutual information, Approximate Entropy, Lempel-Ziv complexity),
- **physical nonlinear time-series analysis**(e.g., correlation dimension, Lyapunov exponent estimates, surrogate data analysis)
- **linear and nonlinear model parameters**, fits, and predictive power (e.g., from autoregressive moving average (ARMA), Holt-Winters…)
- ….

Много разных параметрических функций от рядов, отражающих разные характеристики

Catch22(Dummy Prefiltering)

- Удаляем фичи, чувствительные к масштабу
- Удаляем фичи, которые выплевывают больше 80% пропусков

- Ряды в датасетах z-score normalized
- Если в задаче важные mean и var это может сильно скинуть качество(catch24)

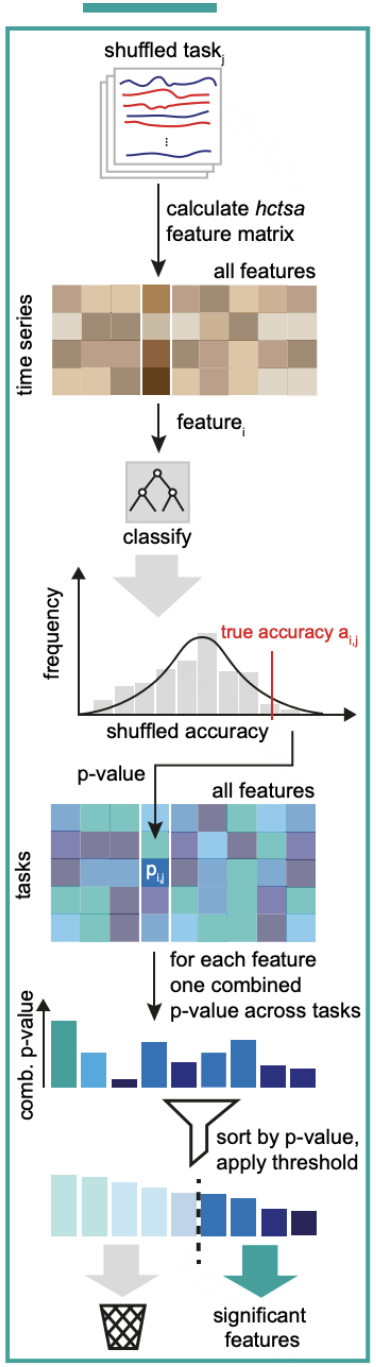
Catch22(Performance Evaluation)

Будем искать фичи, которые хорошо работают индивидуально -> оцениваем качество классификатора на 1 фиче

Catch22(Statistical prefiltering)

Удалим фичи, которые перформят как рандом:

- Строим распределение качества случайного классификатора(нормальное)
- Тестируем гипотезу ”accuracy_random < accuracy_algo”
- Делаем коррекцию на множественное тестирование гипотез(Holm-Bonferroni)
- Отбираем значимые фичи



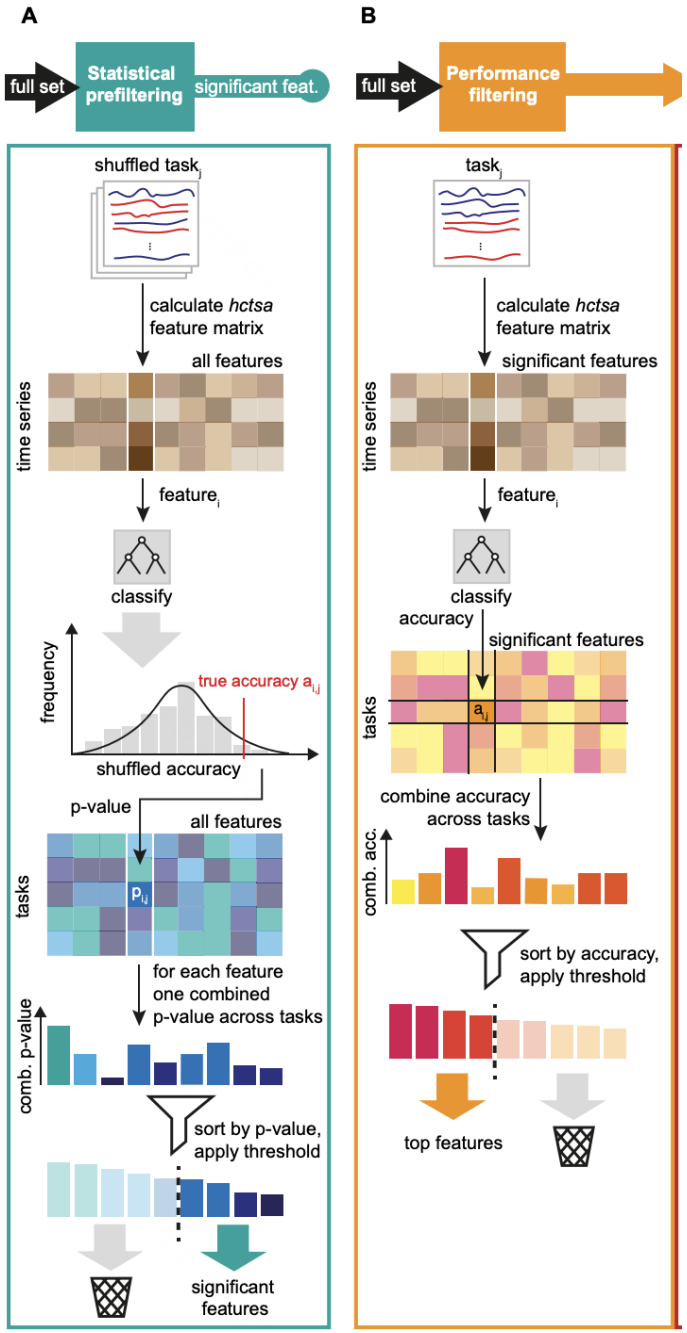
Catch22(Performance Filtering)

Берем топ-N лучших фичей:

- Считаем скоры для каждой задачи score = mean class-balanced classification accuracy
- Нормализация на среднее accuracy по таску
- Performance фичи = среднее нормализованное accuracy

$$a^{\mathrm{n}}_{i,j} = \frac{a_{i,j}}{\bar{a}_i}.$$

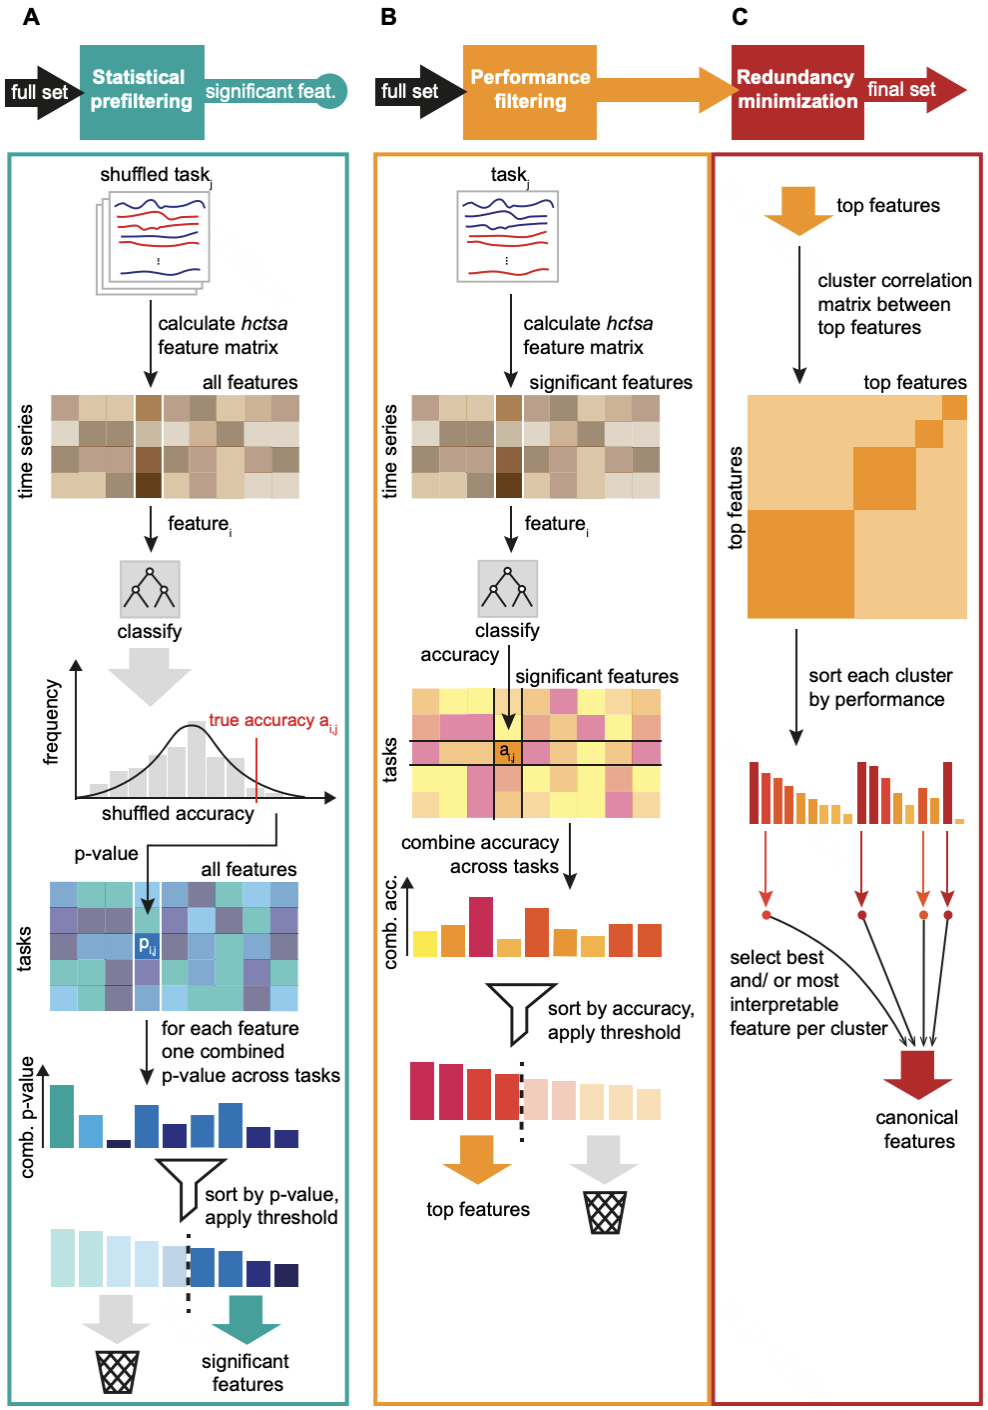
$$a^{\mathrm{n,c}}_{i} = \frac{1}{M}\sum_{j=1}^{M} a^{\mathrm{n}}_{i,j}$$



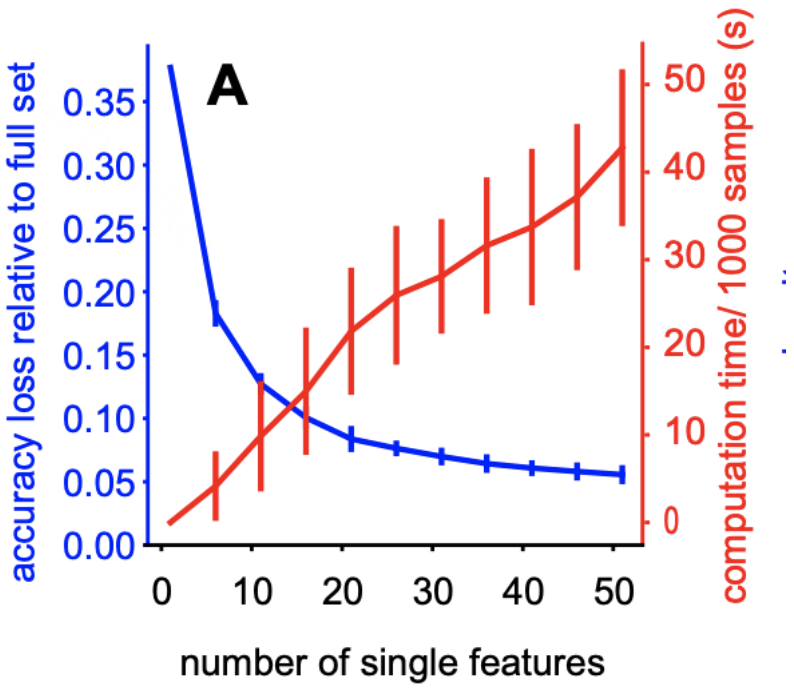
Catch22(Redundancy minimization)

Отбираем максимально разнообразные фичи

- Иерархическая кластеризация на корреляции векторов перформанса
- Из кластера по фиче – лучший перформас среди фичей в кластере + руками



Catch22(Эксперименты)

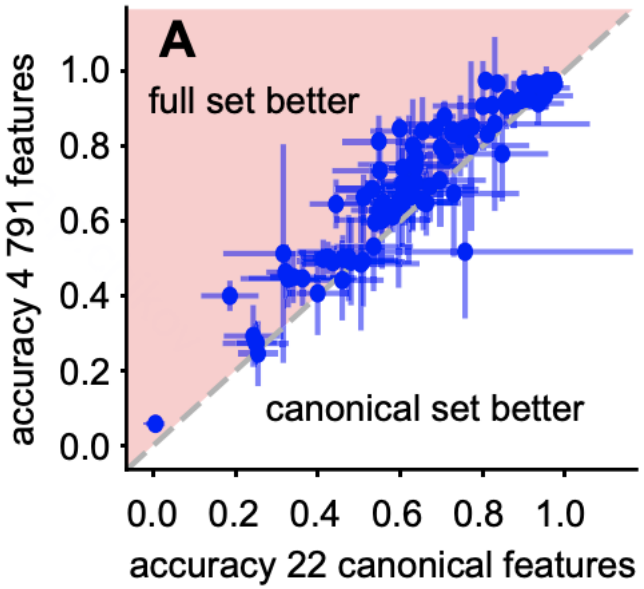


- При 20 фичах(кластерах) точность практически не проседает(5%)
- Большая дисперсия по компьют, но не по качеству от N

- Синяя – относительная потеря точности
- Красная – Время подсчета фичей
- Усы – N от 100 до 1000

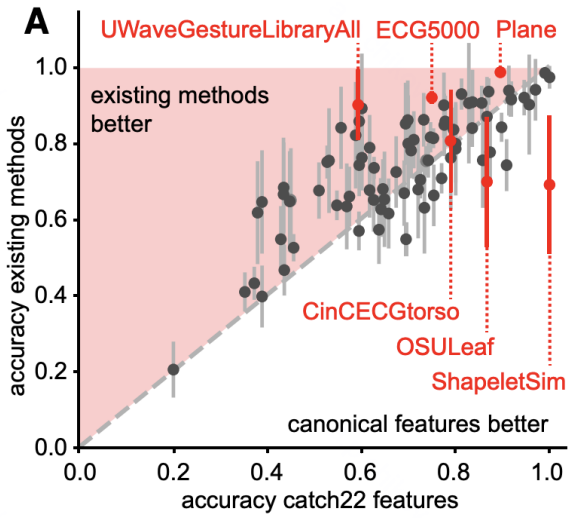
Catch22(Эксперименты)

- В среднем работает не сильно хуже
  - catch22 ~72%
  - 4791 features ~77%
- На конкретных задачах даже обыгрывает полный набор или такое же качество

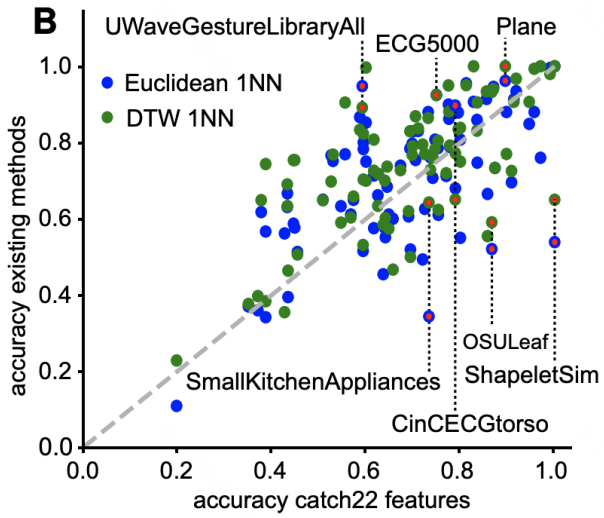


Сравнение качества для разных наборов фичей

Catch22(Эксперименты)



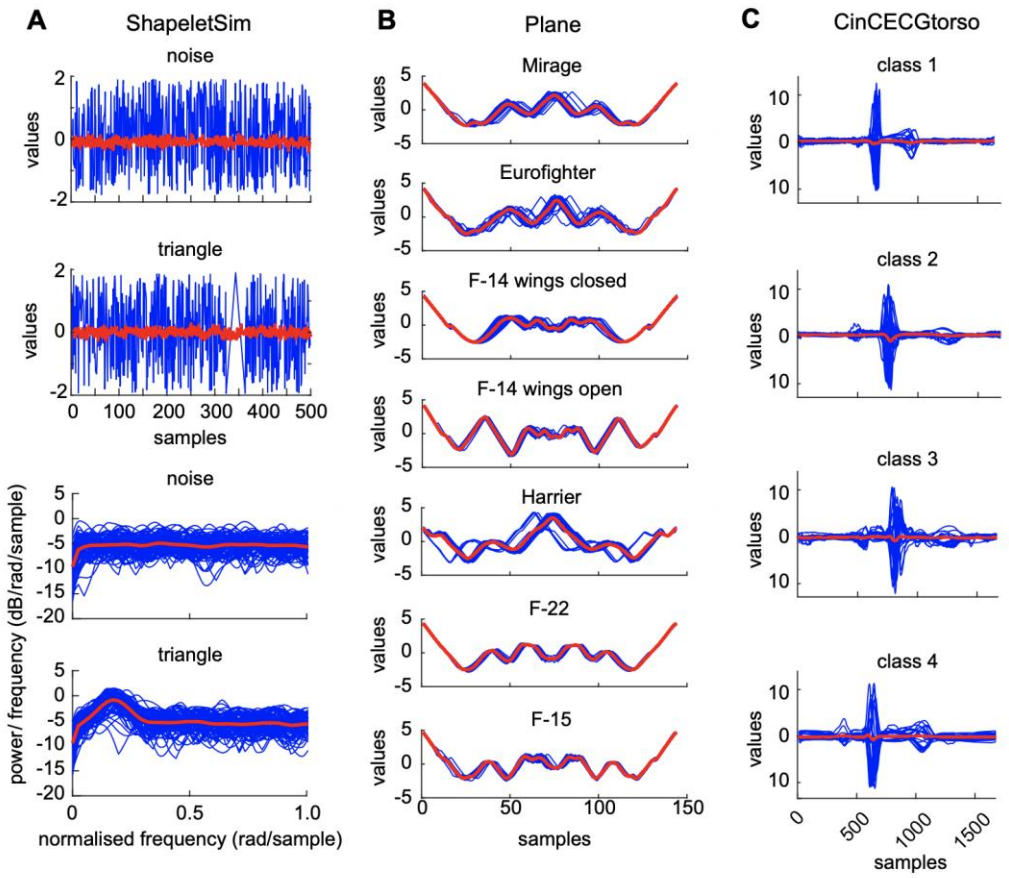
Сравнение с классификационными подходами



Сравнение с KNN

- Тоже неплохо, но где-то заметно хуже
- Для части датасетов важна “форма рядов” или наличие паттернов

Catch22(Эксперименты)



Feature + shape лучше

Shape лучше

Feature лучше

- Для части датасетов важна “форма рядов” или наличие паттернов

Kats + Meta Learning

Kats

- Использовали 40 фичей для Meta-learning
- 6-20х ускорили подбор модели и гиперпараметров

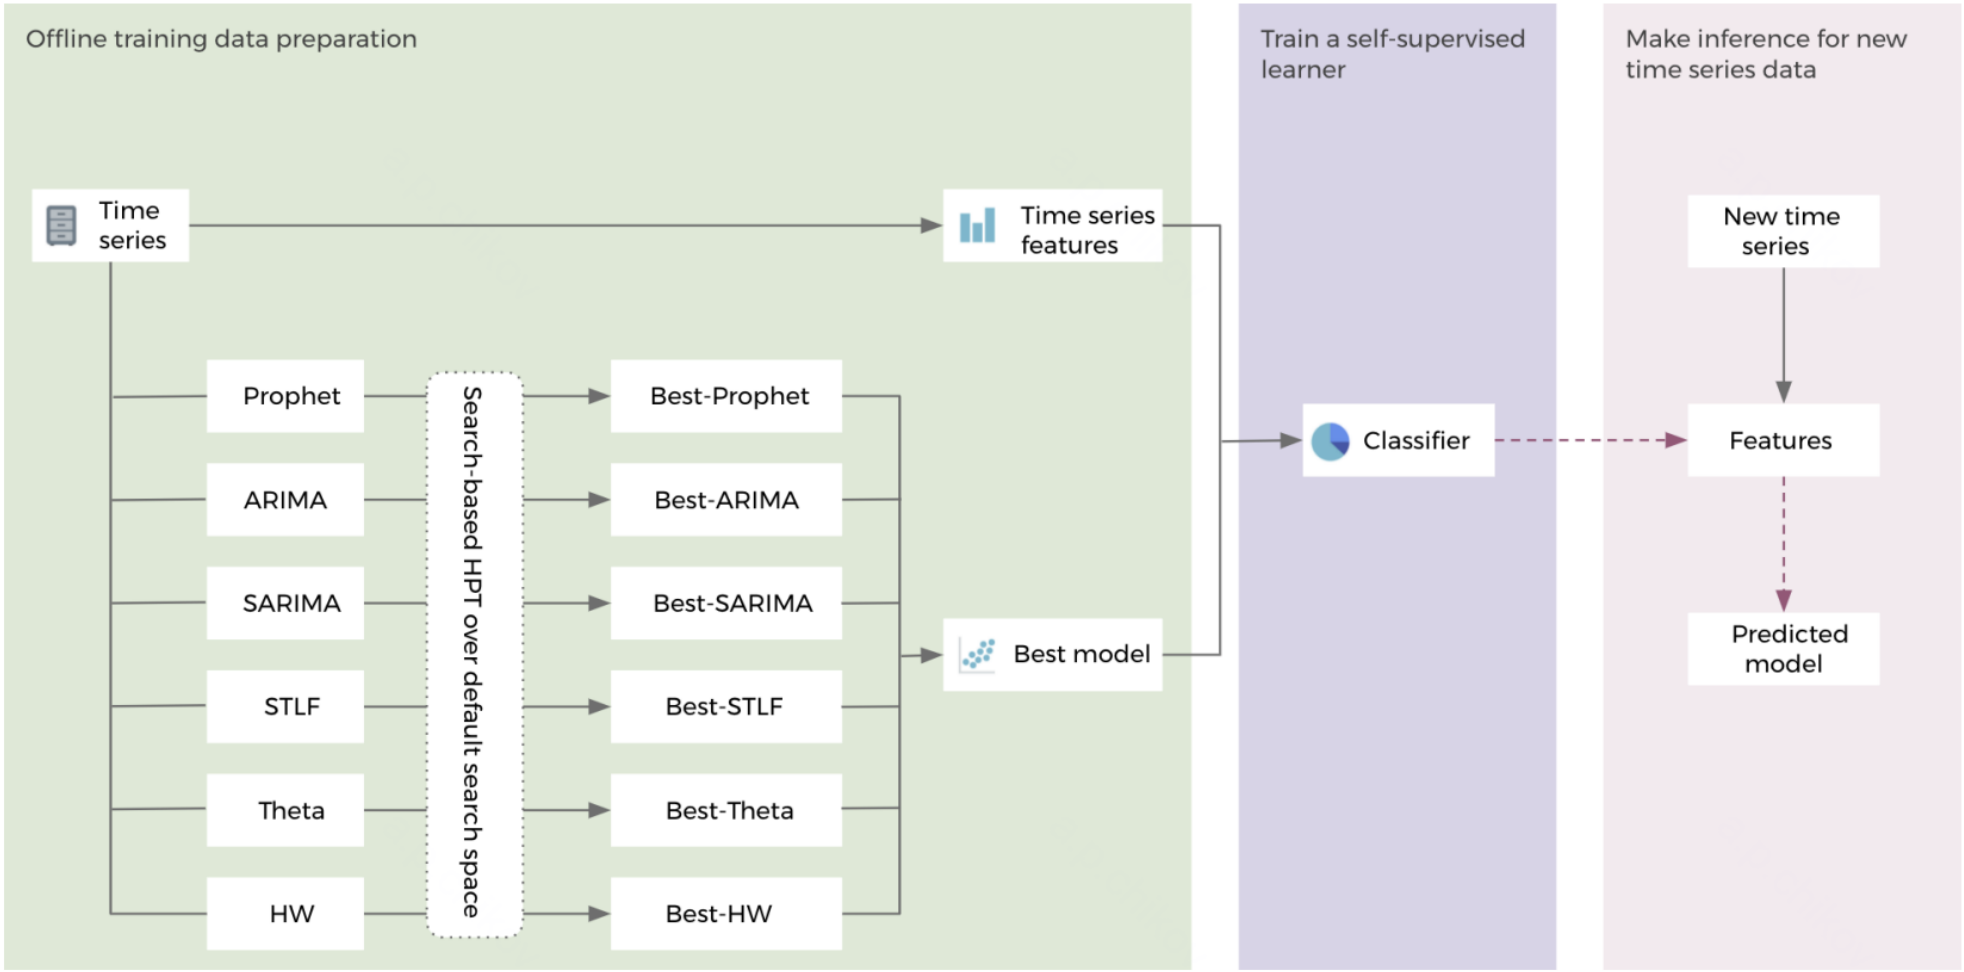
Self-supervised learning for fast and scalable time series hyper-parameter tuning

Kats(Признаки)

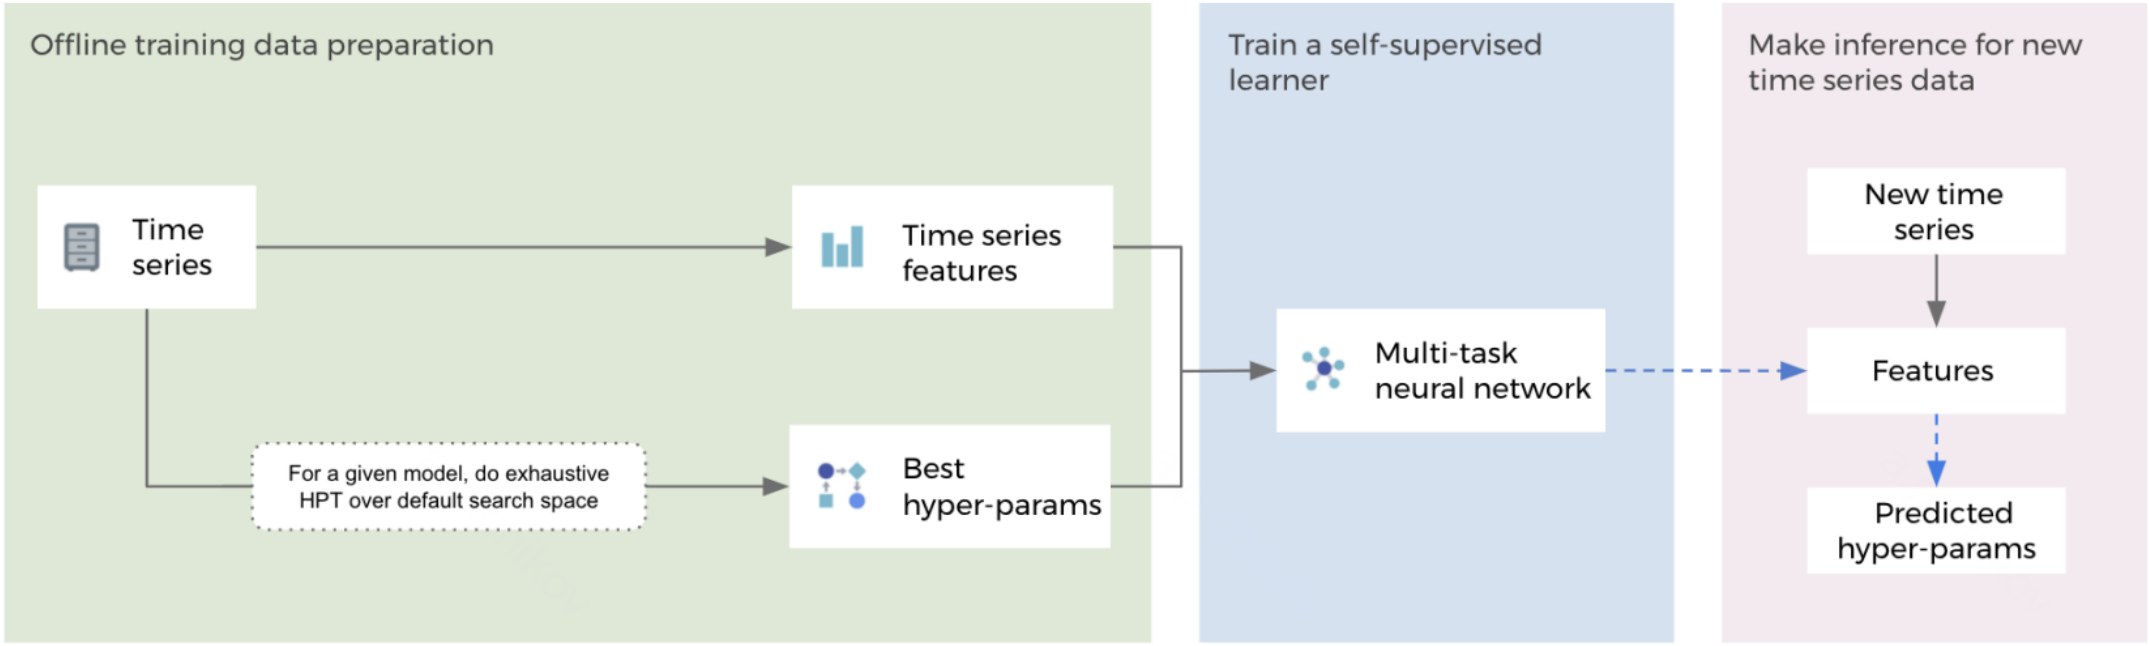
Примеры признаков

- **Spectral entropy**: Shannon entropy of spectral density function.
- **Lumpiness**: variance of variances within non-overlapping windows
- **Stability**: variance of means within non-overlapping
- **Trend/Seasonal strength**: Trend strength is the variance explained by STL trend term, and seasonal strength is the variance explained by STL seasonality terms
- **Holt-Winter's Parameters:** estimates the smoothing parameter for the level-alpha, trend-beta of HW's linear trend, and additive seasonal trend-gamma.

Kats(Подбор модели)

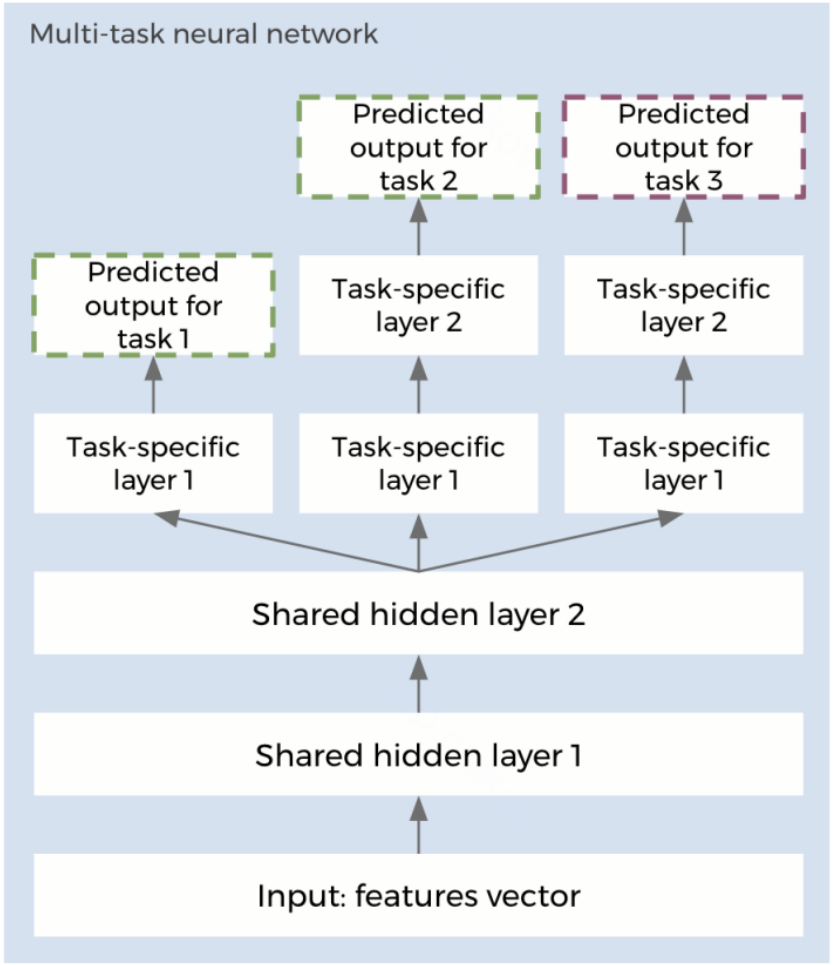


Kats(Подбор гиперпараметрво)



Kats(Подбор гиперпараметрво)

- Отдельная сетка на каждую модель
- Отдельная голова на каждый гиперпараметр
- Parameter Sharing



Kats: Датасет(набор данных)

Данные
- Facebook -- 2,852 рядов из разных доменов
- M3-Competition -- 1,428 месячных рядов из разных доменов

Модели
STLF, Theta, Prophet, ARIMA, SARIMA, and Holt-Winter's

Результирующий датасет:
- *best_model* – лучшая модель
- *best_hpt* – лучшие гиперпараметры

(по 20 случайных сэмплов на модель)

Модель	Гиперпараметры
Prophet	seasonality_mode ∼ Categorical["additive "multiplicative"]
	seasonality_prior_scale ∼ LogUniform[0.01, 10]
	changepoint_prior_scale ∼ LogUniform[0.001, 0.5]
	changepoint_range ∼ Uniform[0.85, 0.95]
	holidays_prior_scale ∼ LogUniform[0.01, 10]
SARIMA	p, d ∼ IntUniform[1, 6]
	q ∼ IntUniform[1, 2]
	P ∼ IntUniform[0, 2]
	D, Q ∼ IntUniform[0, 1]
	s ∼ Categorical[0, 7, 30]
Holt-Winters	trend, seasonal ∼ Categorical["add "mul null]
	damped_trend, use_boxcox ∼ Categorical[False, True]
	seasonal_periods ∼ Categorical[7, 30, null]
SMA	window ∼ IntUniform[1, 10]
	seasonality ∼ Categorical[1, 7, 30]
Linear	l1_ratio ∼ Uniform[0, 1]
	alpha ∼ LogUniform[0.00001, 1000]
	lags ∼ IntUniform[15, 57]
	use_log, use_std ∼ Categorical[False, True]
	linear_trend, date_flags ∼ Categorical[False, True]

Kats: Оценка качества

1. Качество работы подобранных моделей(**не важны ошибки классификации**)

$$SMAPE = \frac{1}{n} \times \sum \frac{| \, forecast \; value \; - actual \; value \, |}{(| \, actual \; value \, | + \, | \, forecast \; value \, |)/2}$$

Учитываем различия в масштабе

2. Качество классификации

$$BalancedAccuracy = \frac{1}{c}\left(\frac{TP_1}{TP_1+FN_1} + \cdots + \frac{TP_c}{TP_c+FN_c}\right)$$

Учитываем дисбаланс классов

Kats(Эксперименты)

Сравним одиночные модели VS оптимальную модель(SSL)

	SSL	Prophet	ARIMA	STLF	SARIMA	HW	Theta
Forecasts MAPE (train)	**0.0871**	0.1154	0.1683	0.1139	0.1253	0.1178	0.1441
MAPE Change % (train)	**Baseline**	-32.4811%	-93.1784%	-30.7371%	-43.8146%	-35.1966%	-65.4825%
Forecasts MAPE (test)	**0.1078**	0.1155	0.1620	0.1142	0.1250	0.1191	0.1437
MAPE Change % (test)	**Baseline**	-7.1096%	-50.2112%	-5.9272%	-15.9224%	-10.4991%	-33.2728%

Table 1: Performance comparison on Facebook Infrastructure data

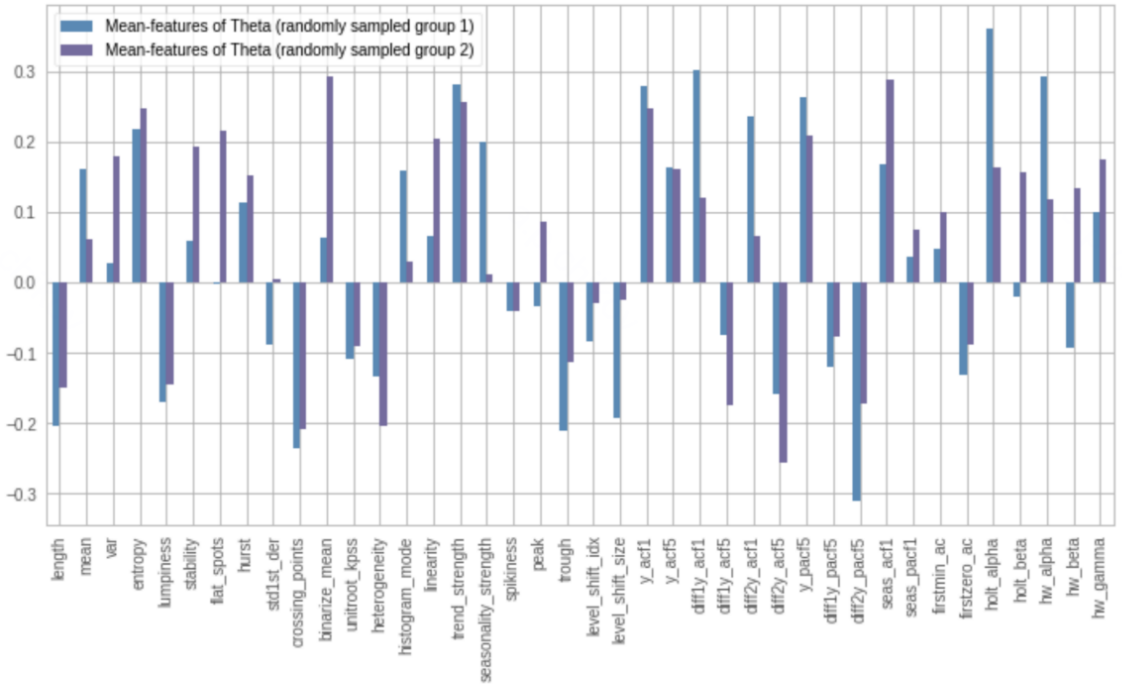
Для получения хорошего качества **достаточно 1000 рядов** (на Facebook датасете)

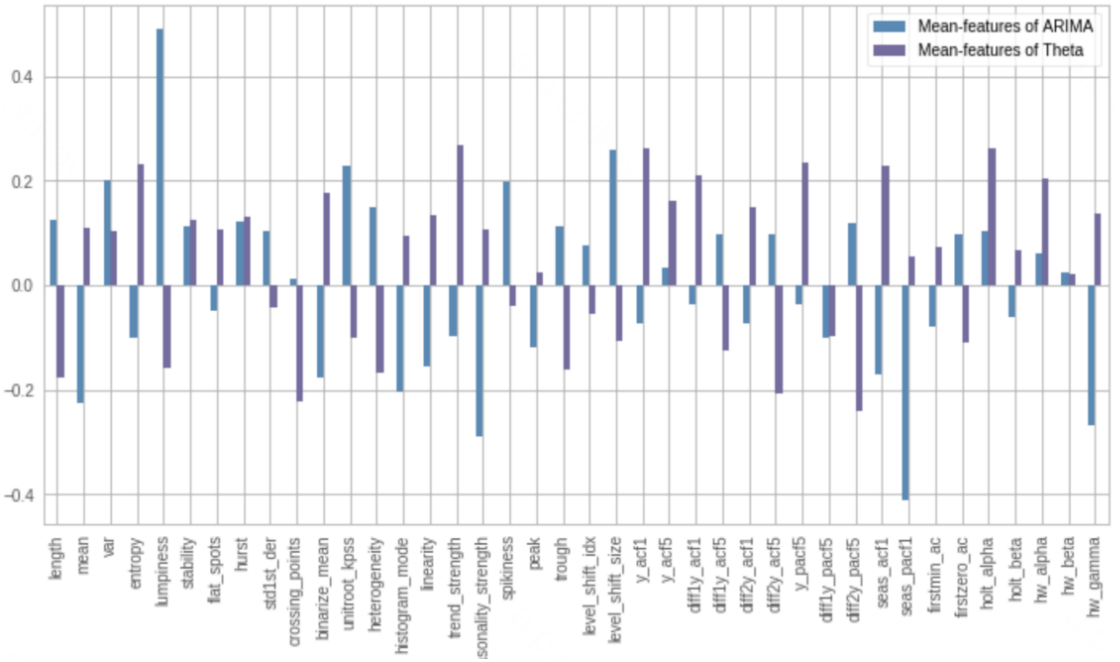
Kats(Эксперименты)

Похожие фичи -> похожие модели

Пример: для разной длины рядов нужны разные модели

- Короткие – простые модели
- Длинные – сложные модели(больше инфы для обучения)





Kats(Эксперименты)

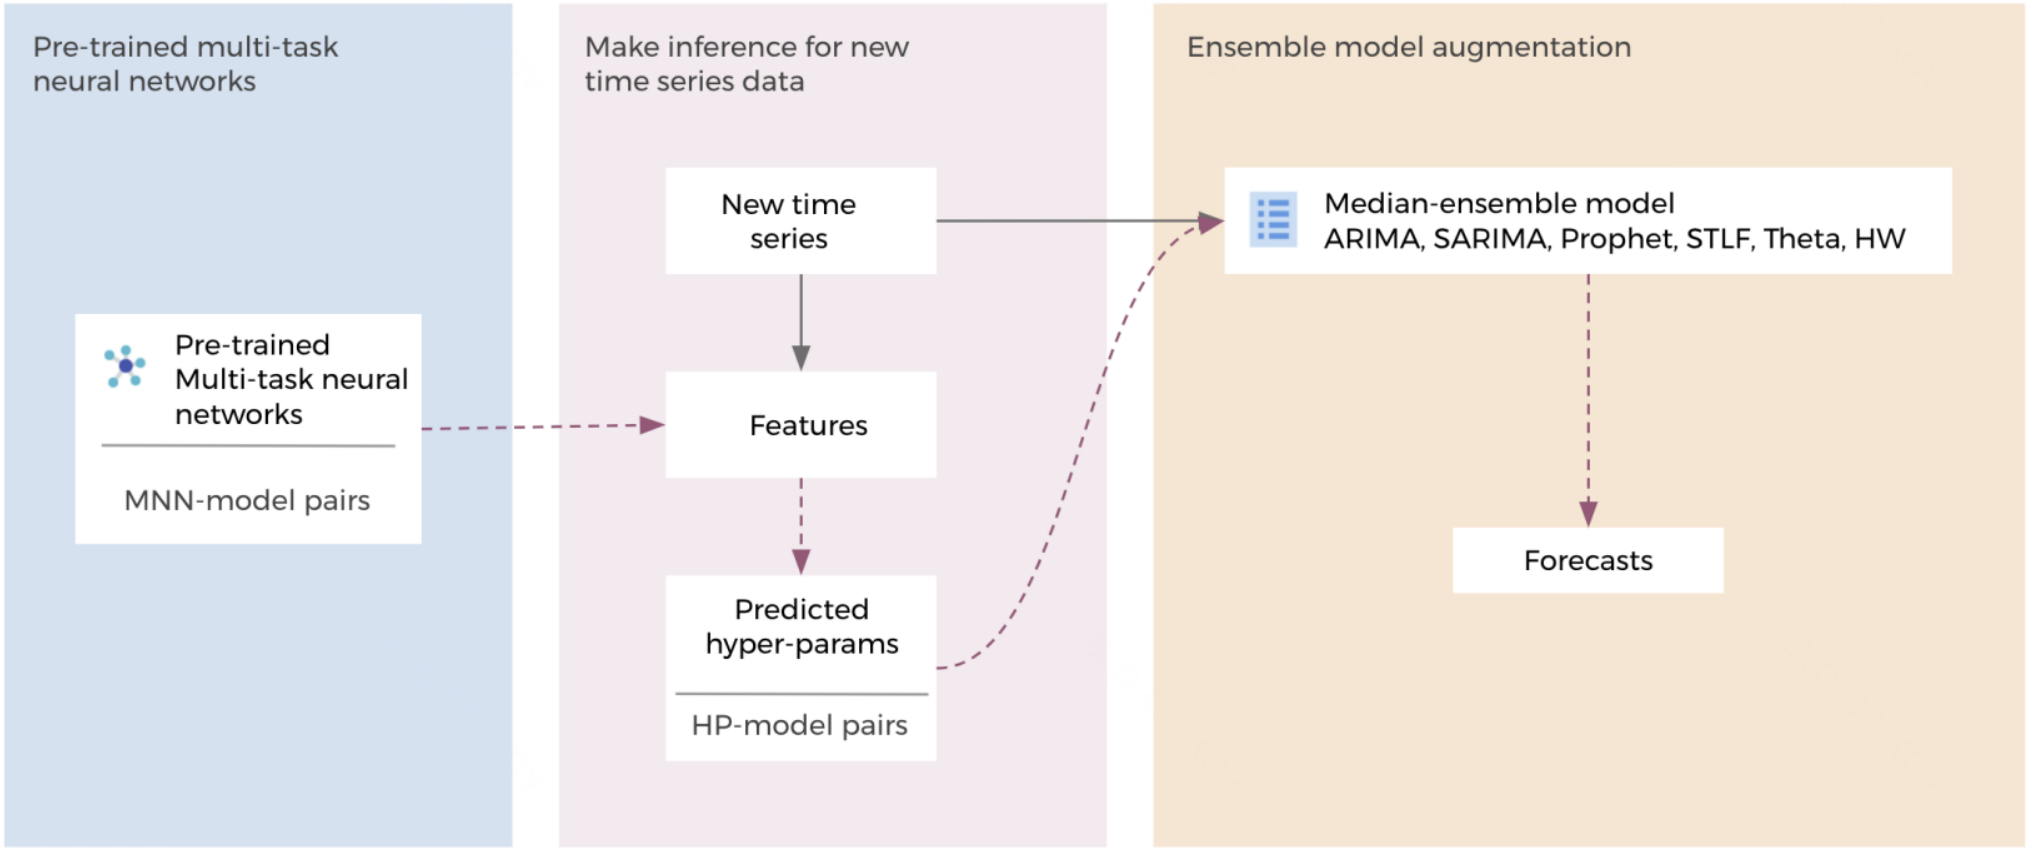
	T + y/2	T + y	T + 1.5 y	T + 2 y
T	**27.00%**	34.50%	33.50%	42.50%
T + y/2	NA	**22.50%**	27.50%	40.50%
T + y	NA	NA	**17.00%**	37.00%
T + 1.5 y	NA	NA	NA	**17.00%**

Table 2: Consistency of model selection

Процент рядов, для которых поменялась оптимальная модель

- Модель меняется со временем
- Длинные ряды более устойчивы к модели
- (практика) Даже на коротких горизонтах есть эффект смены модели

Kats(Эксперименты)



Подберем гиперпараметры для ансамбля

Kats(Эксперименты)

		Method	Avg-MAPE	% Avg-MAPE Change	Median-MAPE	% Median-MAPE Change	# Fails	Runtime
Ensemble Model	1	Ensemble + HP	**0.111**	**-54.502%**	**0.096**	**-38.407%**	0	6*20=120
	2	Ensemble + Random-HP	0.154	-36.629%	0.130	-16.517%	0	6*1=6
	3	Ensemble + SSL-HPT	0.139	-42.917%	0.116	-25.379%	0	6*1=6
Random Model	4	Random model + HP	0.128	-47.372%	0.104	-32.976%	0	1*20=20
	5	Random model + Random-HP	0.243	**Baseline**	0.155	**Baseline**	12	1*1=1
	6	Random model + SSL-HPT	0.178	-26.889%	0.128	-17.252%	3	1*1=1
SSL-MS	7	SSL-MS + HP	**0.113**	**-53.639%**	**0.090**	**-42.174%**	0	1*20=20
	8	SSL-MS + Random-HP	0.278	14.536%	0.162	4.020%	24	1*1=1
	9	SSL-MS + SSL-HPT	0.168	-30.787%	0.124	-20.401%	5	1*1=1

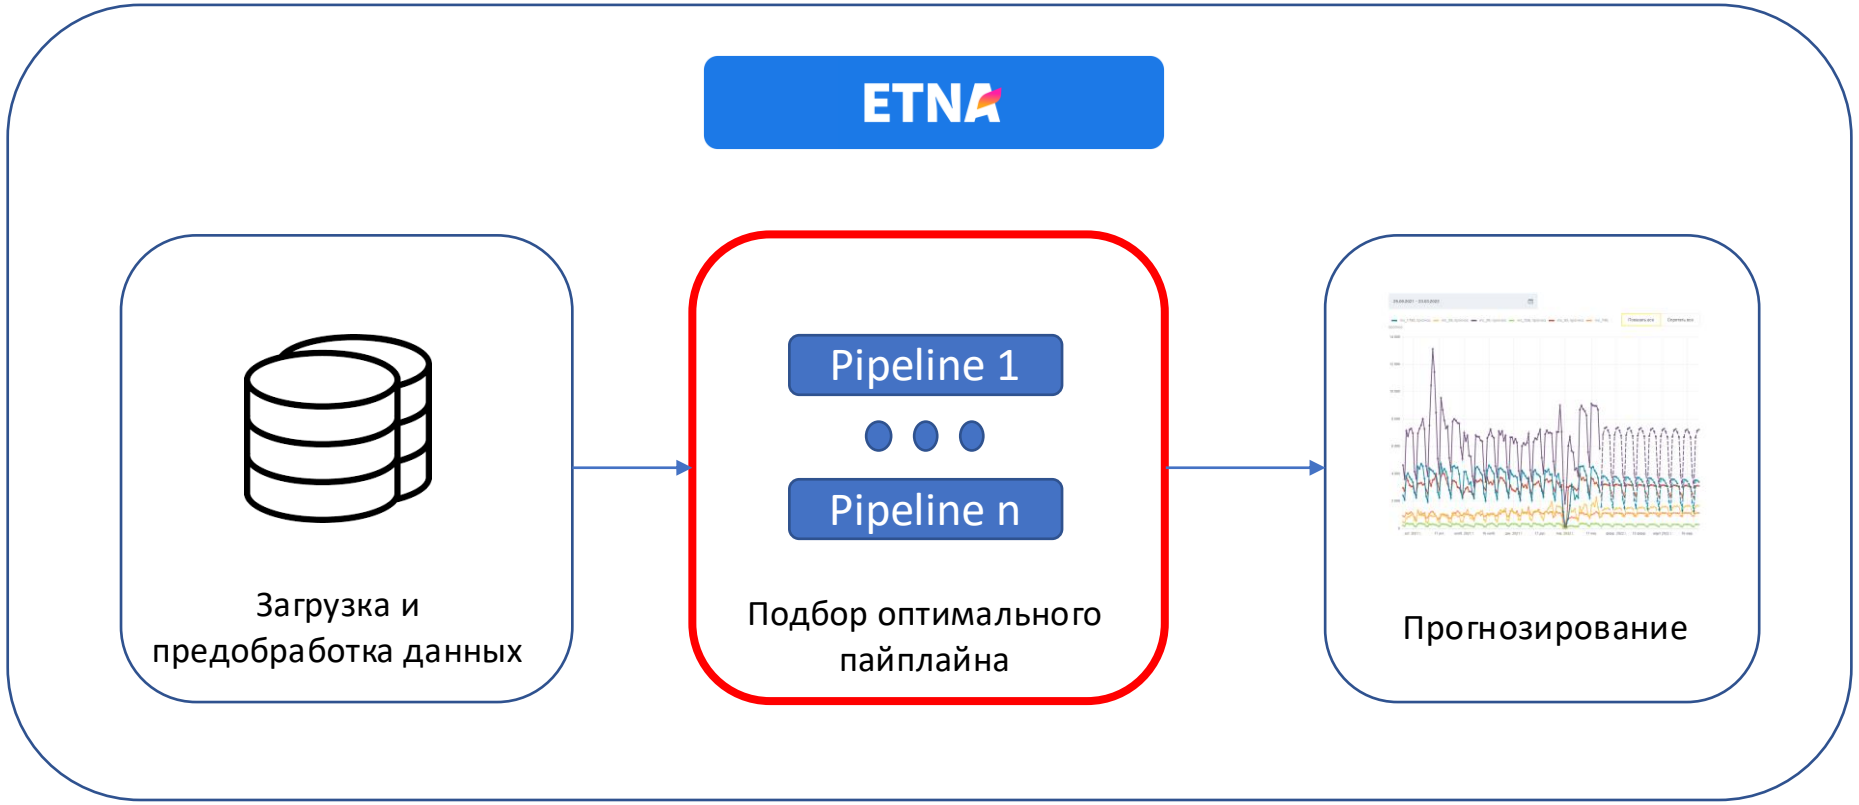
Table 3: Overall comparison on Facebook Infrastructure data

Сравним

- Ансамбль
- Случайную модель
- Модель, подобранную через Meta-Learning

Meta-Learning + Ансамблирование выигрывает
(вот это поворот)

Где можно применить



- Вместо кросс-валидацию используем предсказания модели
- Учим модель на истории кросс-валидации